P.PORTO

ESCOLA SUPERIOR DE TECNOLOGIA E GESTÃO

MongoDB: Framework de Agregação

Bruno Oliveira (bmo@estg.ipp.pt)

PEI Processamento Estruturado de Informação

Agenda

- MongoDB: Framework de agregação
  - Match
  - Project
  - Sort, skip e count
  - Sample
  - Group
  - Unwind
  - Lookup

Introdução

- No MongoDB, há duas formas básicas de recuperação de dados: através de consultas com o find() e através da análise utilizando a aggregation framework através da função aggregate();
- find() permite filtrar resultados, fazer transformações básicas de documentos, ordenar os documentos, limitar o conjunto de resultados de documentos, etc;

Framework de agregação

- A agregação no MongoDB permite a transformação de dados de forma mais poderosa do que a utilização do comando find();
- Através da utilização de múltiplas fases (stages) e expressões, é possível construir um "pipeline" de operações sobre os seus dados para realizar operações analíticas;
- Cada stage transfere a saída padrão para algum outro destino. A saída de um stage é enviada para outro stage para processamento posterior.

Framework de agregação

- Os documentos entram numa pipeline de várias etapas que os transforma num resultado agregado.

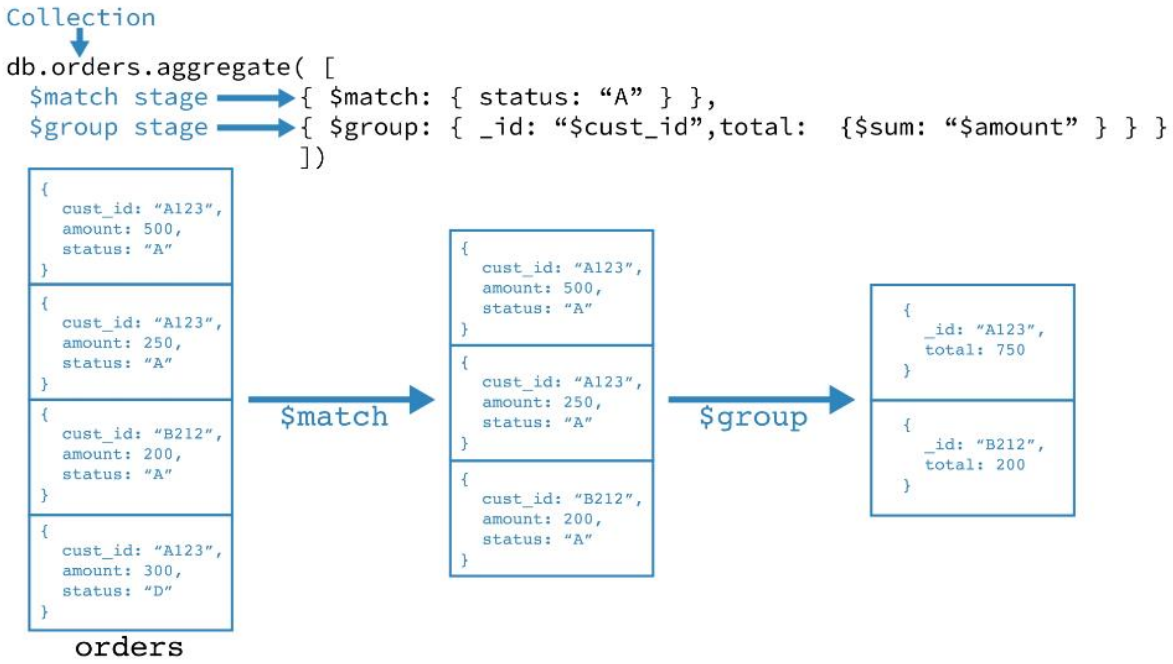

https://docs.mongodb.com/manual/aggregation/

Framework de agregação

```
db.orders.aggregate([
          { $match: { status: "A" } },
          { $group: { _id: "$cust_id", total: { $sum: "$amount" } } }
])
```

- Primeira etapa: a etapa: $match filtra os documentos pelo campo de status e passa para a próxima etapa aqueles documentos com status igual a "A";
- Segunda etapa: a etapa $group agrupa os documentos pelo campo cust_id para calcular a soma do valor para cada cust_id exclusivo.

Framework de agregação utilizando Mongo Compass

Documents 25.4K | Aggregations | Schema | Indexes 1 | Validation

Your pipeline is currently empty. Need help getting started? Generate aggregation

Explain | Export | Run | Options

Untitled | SAVE | CREATE NEW | EXPORT TO LANGUAGE | PREVIEW | STAGES | TEXT | WIZARD

25359 Documents in the collection

Preview of documents

```
_id: ObjectId('5eb3d668b31de5d588f4292a')
▸ address : Object
borough : "Brooklyn"
cuisine : "American"
▸ grades : Array (4)
name : "Riviera Caterer"
restaurant_id : "40356018"
```

```
_id: ObjectId('5eb3d668b31de5d588f4292b')
▸ address : Object
borough : "Brooklyn"
cuisine : "Delicatessen"
▸ grades : Array (6)
name : "Wilken'S Fine Food"
restaurant_id : "40356483"
```

```
_id: ObjectId('5eb3d668b31de5d588f429
▸ address : Object
borough : "Staten Island"
cuisine : "Jewish/Kosher"
▸ grades : Array (4)
name : "Kosher Island"
restaurant_id : "40356442"
```

+ Add Stage

Learn more about aggregation pipeline stages

Framework de agregação utilizando Mongo Compass

```
_id: ObjectId('5eb3d668b31de5d588f4292a')
▸ address : Object
  borough : "Brooklyn"
  cuisine : "American"
▸ grades : Array (4)
  name : "Riviera Caterer"
  restaurant_id : "40356018"
```

```
_id: ObjectId('5eb3d668b31de5d588f4292b')
▸ address : Object
  borough : "Brooklyn"
  cuisine : "Delicatessen"
▸ grades : Array (6)
  name : "Wilken'S Fine Food"
  restaurant_id : "40356483"
```

```
_id: ObjectId('5eb3d668b31de5d588f4292c')
▸ address : Object
  borough : "Staten Island"
  cuisine : "Jewish/Kosher"
▸ grades : Array (4)
  name : "Kosher Island"
  restaurant_id : "40356442"
```

```
_id: ObjectId('5eb3d668b31de5d588f4292d')
▸ address : Object
  borough : "Brooklyn"
  cuisine : "Hamburgers"
▸ grades : Array (4)
  name : "Wendy'S"
  restaurant_id : "30112340"
```

Steps

Stage 1 $match

```
/**
 * query: The query in MQL.
 */
{
  cuisine:"Bakery"
}
```

Output after $match stage (Sample of 10 documents)

```
_id: ObjectId('5eb3d668b31de5d588f4292e')
▸ address : Object
  borough : "Bronx"
  cuisine : "Bakery"
▸ grades : Array (5)
  name : "Morris Park Bake Shop"
  restaurant_id : "30075445"
```

```
_id: ObjectId('5eb3d668b31de5d588f4294c')
▸ address : Object
  borough : "Manhattan"
  cuisine : "Bakery"
▸ grades : Array (5)
  name : "Olive'S"
  restaurant_id : "40363151"
```

```
_id: ObjectId('5eb3d668b31de5d588f42aaa')
▸ address : Object
  borough : "Brooklyn"
  cuisine : "Bakery"
▸ grades : Array (4)
  name : "Tropical House Baking Co."
  restaurant_id : "40372596"
```

Stage 2 $group

```
/**
 * _id: The id of the group.
 * fieldN: The first field name.
 */
{
  _id: "$borough",
  NumberOfRestaurants: {
    $sum: 1
  }
}
```

Output after $group stage (Sample of 6 documents)

```
_id: "Bronx"
NumberOfRestaurants : 71
```

```
_id: "Missing"
NumberOfRestaurants : 2
```

```
_id: "Brooklyn"
NumberOfRestaurants : 173
```

Preview

Framework de agregação

```
db.solarSystem.aggregate([{
  "$match": {
    "atmosphericComposition": { "$in": [/O2/] },
    "meanTemperature": { $gte: -40, "$lte": 40 }
  }
}, {
  "$project": {
    "_id": 0,
    "name": 1,
    "hasMoons": { "$gt": ["$numberOfMoons", 0] }
  }
}]);
```

Output

```
[ { name: 'Earth', hasMoons: true } ]
```

- Neste exemplo, $match e $project são operadores de agregação e $in, $gte e $lte são operadores de consulta;
- Na etapa de projeção ($project), $gt é uma expressão. Os seus argumentos são fornecidos no array.

Exemplo que utiliza dataset: solarSystem (https://www.mongodb.com/docs/atlas/sample-data/#std-label-load-sample-data)

Framework de agregação

- O operador $match filtra os documentos, enviando para a próxima etapa os documentos que correspondem às condições especificadas;
- Podemos utilizar o operador $match várias vezes;
- Podemos realizar correspondências com base em comparação, lógica, arrays e muito mais;

Framework de agregação - Match

- Se o operador $match for incluído na primeira etapa, pode tirar partido de índices, o que aumenta a velocidade das consultas;
- O $match deve ser incluído no início dos pipelines;
- O operador $match não possui nenhum mecanismo de projeção.

Framework de agregação - Match

- Exemplo:

```
// filtra todos os corpos celestiais que não são “Star”
db.solarSystem.aggregate([{
  "$match": { "type": { "$ne": "Star" } }
}]).pretty()
```

Framework de agregação - Match

- Exemplos:

```
// Contar o número de documentos (sem utilizar framework de agregação)
db.solarSystem.count();

// utilizando o operador $count (utilizando framework de agregação)
db.solarSystem.aggregate([{
  "$match": { "type": { "$ne": "Star"} }
}, {
  "$count": "planets"
}]);
```

Framework de agregação - Project

- Passa os documentos com os campos solicitados para a próxima etapa do pipeline;
- Os campos especificados podem ser campos existentes dos documentos de entrada ou campos recém-calculados.

Framework de agregação - Project

- Exemplos:

```
//Remove o campo: _id do documento projetado utilizando a função find
db.solarSystem.find({}, {"_id": 0, "name": 1});

// projeta o campo``name`` e remove o campo``_id`` com função aggregate
db.solarSystem.aggregate([{ "$project": { "_id": 0, "name": 1 } }]);

// utilização da notação "dot" para expressar os campos para projeção
db.solarSystem.aggregate([
        { "$project": { "_id": 0, "name": 1,
                        "gravity.value": 1 }
        }
]);
```

Framework de agregação - Project

- Exemplos:

```
// Atribuir o valor da gravidade a um campo: “gravity”
db.solarSystem.aggregate([
                    {"$project": {
                        "_id": 0, "name": 1,
                        "gravity": "$gravity.value" }}]);

// Criar um novo campo: “myWeight” utilizando expressões
db.solarSystem.aggregate([
   {"$project": { "_id": 0, "name": 1,
                "myWeight": { "$multiply":
                              [ { "$divide":
                              [ "$gravity.value", 9.8 ] }, 86 ]
                            } }
                }
]);
```

Framework de agregação - Project

- Com este operador pode-se executar operações de acumulação ($sum, $avg, $max, $min) tal como o $group.
- No entanto, enquanto o $group opera sobre conjuntos de documentos, o $project opera sobre um array (de um documento individual).
- Exemplo:

```
db.restaurants.aggregate([
  {$project: {scoreMedio: {$avg: "$grades.score"}}}
  ])
```

```
{ _id: ObjectId("61b1e344d55170cefd6c734a"), scoreMedio: 8.2 }
{ _id: ObjectId("61b1e344d55170cefd6c734b"), scoreMedio: 13.75 }
{ _id: ObjectId("61b1e344d55170cefd6c734c"), scoreMedio: 9.25 }
```

Framework de agregação - AddFields

- O operador de estágio $addFields é similar ao $project, mas mantém todos os campos do documento original. Este operador permite adicionar novos campos ou substituir campos existentes.

```
db.restaurants.aggregate([
  {
    $addFields: {
      scoreMedio:
      {$avg: "$grades.score"}
    }
  }
])
```

```
{ _id: ObjectId("61b1e344d55170cefd6c734a"),
  address:
   { building: '1007',
     coord: [ -73.856077, 40.848447 ],
     street: 'Morris Park Ave',
     zipcode: '10462' },
  borough: 'Bronx',
  cuisine: 'Bakery',
  grades:
   [ { date: 2014-03-03T00:00:00.000Z, grade: 'A', score: 2 },
     { date: 2013-09-11T00:00:00.000Z, grade: 'A', score: 6 },
     { date: 2013-01-24T00:00:00.000Z, grade: 'A', score: 10 },
     { date: 2011-11-23T00:00:00.000Z, grade: 'A', score: 9 },
     { date: 2011-03-10T00:00:00.000Z, grade: 'B', score: 14 } ],
  name: 'Morris Park Bake Shop',
  restaurant_id: '30075445',
  scoreMedio: 8.2 }
```

Framework de agregação - Out

- O operador de estágio $out guarda os documentos resultantes da pipeline de agregação numa coleção especificada. Se essa coleção já existe, é substituída pelo resultado da pipeline. Caso contrário, cria uma nova coleção.
- O operador $out deverá corresponder ao último estágio da pipeline.
- Exemplo:

```
db.restaurants.aggregate([
  {
     $addFields: {scoreMedio:
       {$avg: "$grades.score"}}},
       {$out: "restaurants_avg"}
  ])
```

Framework de agregação – Sort, Skip e count

- $sort, $skip, $limits e $count são funcionalmente equivalentes aos métodos de cursor;
- O $sort necessita de um campo para critério de ordenação;
- Um aspeto importante para se referir é que a ordenação não se limita apenas a um único campo;
- Por padrão, a ordenação está limitada a 100 megabytes de RAM. Se for necessária mais memória, é necessário fornecer a opção allowDiskUse = true para o pipeline.

Framework de agregação – Sort, Skip e count

- Exemplos - Sort:

```
// ordena documentos com método de cursor
db.solarSystem.find({}, { "_id": 0,
                          "name": 1,
                          "numberOfMoons": 1 })
                             .sort( {"numberOfMoons": -1 } ).pretty();
// ``$sort`` stage
db.solarSystem.aggregate([{
  "$project": {
    "_id": 0,
    "name": 1,
    "numberOfMoons": 1
   }
 }, {
  "$sort": { "numberOfMoons": -1 }
}]).pretty();
```

Framework de agregação – Sort, Skip e count

- Exemplos - Sort:

```
// opção ``allowDiskUse``
db.solarSystem.aggregate([{
  "$project": {
    "_id": 0,
    "name": 1,
    "hasMagneticField": 1,
    "numberOfMoons": 1
  }
}, {
  "$sort": { "hasMagneticField": -1, "numberOfMoons": -1 }
}],
{ "allowDiskUse": true });
```

permite a escrita de ficheiros temporários em disco quando um stage excede o limite de 100 megabytes

Framework de agregação – Sort, Skip e count

- Exemplos - Skip:

```
// descartar documentos utilizando método de cursor
db.solarSystem.find({}, {"_id": 0, "name": 1, "numberOfMoons":
1}).skip(5).pretty();

// ``skip`` stage
db.solarSystem.aggregate([{
  "$project": {
    "_id": 0,
    "name": 1,
    "numberOfMoons": 1
  }
}, {
  "$skip": 1
}]).pretty()
```

Framework de agregação – Sort, Skip e count

- Exemplos - limit:

```
// limitar número de documentos utilizando método de cursor
db.solarSystem.find({}, {"_id": 0, "name": 1, "numberOfMoons":
1}).limit(5).pretty();

// ``$limit`` stage
db.solarSystem.aggregate([{
  "$project": {
    "_id": 0,
    "name": 1,
    "numberOfMoons": 1
  }
},
{ "$limit": 5  }]).pretty();
```

Framework de agregação – Sort, Skip e count

- Exemplos - count:

```
// ``$count`` stage
db.solarSystem.aggregate([{
  "$match": {
    "type": "Terrestrial planet"
  }
}, {
  "$project": {
    "_id": 0,
    "name": 1,
    "numberOfMoons": 1
  }
}, {
  "$count": "terrestrial planets"
}]).pretty();
```

Framework de agregação – Sample

- $sample é muito útil ao trabalhar com grandes coleções em que queremos apenas uma quantidade limitada de documentos para operar;
- Pode ser útil para realizar uma análise inicial ou para fazer alguma amostragem no conjunto de resultados;
- Exemplo:

```
db.nycFacilities.aggregate([{"$sample": { "size": 200 }}]).pretty();
```

Framework de agregação – Group

- Documentos com valores idênticos são agrupados e cada valor único produz um documento de saída que nos mostra os valores ou valores nos quais agrupamos;
- Podemos especificar campos adicionais que desejamos calcular na fase de grupos;
- _id é onde especificamos como os documentos devem ser agrupados;
- O $group pode ser utilizado várias vezes num pipeline.

Framework de agregação – Group

- Exemplo:

```
// Agrupa por ano e conta por ano
db.movies.aggregate([
  {
    "$group": {
      "_id": "$year",
      "numFilmsThisYear": { "$sum": 1 }
    }
  }
])
```

Framework de agregação – Group

- Exemplo:

```
// agrupar e ordenar por ordem descendente baseado na contagem
db.movies.aggregate([
  {
    "$group": {
      "_id": "$year",
      "count": { "$sum": 1 }
    }
  },
  {
    "$sort": { "count": -1 }
  }
])
```

Framework de agregação – Group

- Exemplo:

```
// agrupar todos os documentos. Por convenção utilizamos o valor null
db.movies.aggregate([
  {
    "$group": {
      "_id": null,
      "count": { "$sum": 1 }
    }
  }
])
```

Framework de agregação – Unwind

- $unwind faz com que os arrays sejam decompostos (descompactados), criando um novo documento para cada entrada onde o valor do campo é agora cada valor do array;
- O operador $unwind só funciona num array;
- O descompactar em grandes coleções com grandes documentos pode levar a problemas de desempenho.

Framework de agregação – Unwind

- Exemplo:

```
  _id: ObjectId("573a1390f29313caabcd414a")
  title: "Baby's Dinner"
  year: 1895
  runtime: 1
  released: 1895-12-28T00:00:00.000+00:00
> cast: Array
  plot: "A baby is seated at a table between its cheerful parents, Auguste and ..."
  fullplot: "A baby is seated at a table between its cheerful parents, Auguste and ..."
  lastupdated: "2015-08-12 00:06:40.657000000"
  type: "movie"
> directors: Array
> imdb: Object
> countries: Array
v genres: Array
    0: "Documentary"
    1: "Short"
```

Podemos realizar a decomposição

Framework de agregação – Unwind

- Exemplo:

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: Array
  0: "Documentary"
  1: "Short"
```

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: "Documentary"
```

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: "Short"
```

Framework de agregação – Unwind

```
[{
    $match: {
        _id: ObjectId("573a1390f29313caabcd414a")
    }
}, {
    $project: {
        title: 1,
        year: 1,
        genres: 1
    }
}, {
    $unwind: {
        path: "$genres"
    }
}]
```

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: Array
  0: "Documentary"
  1: "Short"
```

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: "Documentary"
```

```
_id: ObjectId("573a1390f29313caabcd414a")
title: "Baby's Dinner"
year: 1895
genres: "Short"
```

Framework de agregação – Unwind

```
// quantidade de género de filmes por ano entre 2010 e 2015
db.movies.aggregate([
  {
    "$match": {
      "year": { "$gte": 1995, "$lte": 2015 }}
  },
  {
    "$unwind": "$genres"
  },
  {
    "$group": {
      "_id": {
        "year": "$year",
        "genre": "$genres"
      },
      "average_rating": { "$avg": "$imdb.rating" }
    }
  },
  {
    "$sort": { "_id.year": -1, "average_rating": -1 }
  }
])
```

No documento original, os géneros são armazenados num array:

```
"genres": [
  "Documentary",
  "Short"
]
```

Framework de agregação – Lookup

- Este operador representa uma junção entre duas coleções;
- Para cada documento de entrada, a etapa $lookup adiciona um novo campo do tipo array cujos elementos são os documentos correspondentes da coleção “unida”;

Framework de agregação – Lookup

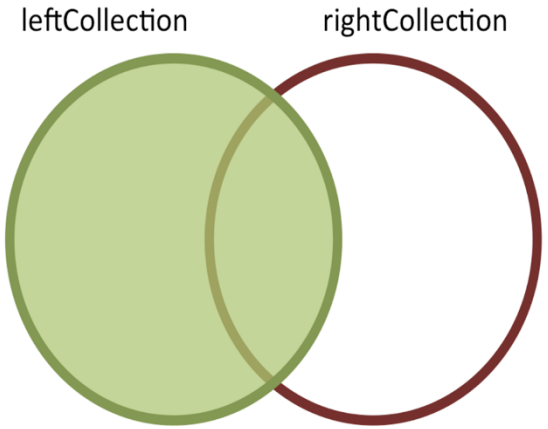

coleção original

```
db.leftCollection.aggregate(
[{
  $lookUp:
    {
      from: “rightCollection”,
      localField: “leftVal”,
      foreignField: “rightVal”,
      as: “embeddedData”
    }
}])
```

coleção a juntar (da mesma BD)

campo a comparar da coleção original
(pode ser um valor individual ou um *array*)

campo a comparar da coleção a juntar (“from”)
(pode ser um valor individual ou um *array*)

novo campo (*array*) com os valores correspondentes da coleção a juntar

Imagem retirada de: https://www.mongodb.com/blog/post/joins-and-other-aggregation-enhancements-coming-in-mongodb-3-2-part-1-of-3-introduction

Framework de agregação – Lookup

```
// lookup que realiza a junção da coleção
air_alliances com a coleção air_airlines
db.air_alliances
  .aggregate([
    {
      "$lookup": {
        "from": "air_airlines",
        "localField": "airlines",
        "foreignField": "name",
        "as": "airlines"
      }
    }
  ])
  .pretty()
```

```
_id: ObjectId("5980bef9a39d0ba3c650ae9b")
name: "Star Alliance"
airlines: Array
  0: Object
    _id: ObjectId("56e9b497732b6122f87903ca")
    airline: 330
    name: "Air Canada"
    alias: "AC"
    iata: "ACA"
    icao: "AIR CANADA"
    active: "Y"
    country: "Canada"
    base: "TAL"
  1: Object
```

Framework de agregação – Lookup

- A etapa $lookup envia esses documentos remodelados para a próxima etapa.
- O campo from é a coleção da qual desejamos consultar os documentos.
- A coleção especificada no campo from não pode ser fragmentada e deve existir na mesma base de dados.

Framework de agregação – Lookup

- Todas as correspondências serão colocadas num array;
- Se não existirem correspondências, o campo conterá um array vazio;
- Os valores de localField e ForeignField são correspondidos através de igualdade;

Framework de agregação – Lookup

- Exemplo:

```
_id: ObjectId("5980bef9a39d0ba3c650ae9b")
name: "Star Alliance"
airlines: Array
  0: "Air Canada"
  1: "Adria Airways"
  2: "Avianca"
  3: "Scandinavian Airlines"
  4: "All Nippon Airways"
  5: "Brussels Airlines"
  6: "Shenzhen Airlines"
  7: "Air China"
  8: "Air New Zealand"
  9: "Asiana Airlines"
  10: "Copa Airlines"
  11: "Croatia Airlines"
  12: "EgyptAir"
  13: "TAP Portugal"
  14: "United Airlines"
  15: "Turkish Airlines"
  16: "Swiss International Air Lines"
  17: "Lufthansa"
  18: "EVA Air"
  19: "South African Airways"
  20: "Singapore Airlines"
```

Para cada valor procura uma correspondência na coleção air_airlines

```
_id: ObjectId("56e9b497732b6122f8790280")
airline: 4
name: "2 Sqn No 1 Elementary Flying Training School"
alias: ""
iata: "WYT"
icao: ""
active: "N"
country: "United Kingdom"
base: "HGH"
```

```
_id: ObjectId("56e9b497732b6122f8790281")
airline: 2
name: "135 Airways"
alias: ""
iata: "GNL"
icao: "GENERAL"
active: "N"
country: "United States"
base: "LHE"
```

Transformação/migração de dados

- Utilizando as funções do mongo (de cursor e aggregate) podemos migrar dados entre coleções e realizar alterações à estrutura dos documentos da coleção;
- Desta forma, podemos importar dados com uma dada estrutura e transformá-los para uma estrutura mais adequada para as consultas que se pretende realizar.

Transformação/migração de dados


```
_id: ObjectId("5ff323e03dbd8828f8c6f5a4")
ReceiptID: "43659"
OrderDate: "2011-05-31 00:00:00.000"
Customer: "29825"
CurrencyRateID: "NULL"
SubTotal: "20565.6206"
TaxAmt: "1971.5149"
Store: "1046"
StoreName: "Better Bike Shop"
ReceiptLineID: "1"
Quantity: "1"
ProductID: "776"
UnitPrice: "2024.994"
LineTotal: "2024.994"
```

```
_id: ObjectId("5ff323e03dbd8828f8c6f5a5")
ReceiptID: "43659"
OrderDate: "2011-05-31 00:00:00.000"
Customer: "29825"
CurrencyRateID: "NULL"
SubTotal: "20565.6206"
TaxAmt: "1971.5149"
Store: "1046"
StoreName: "Better Bike Shop"
ReceiptLineID: "2"
Quantity: "3"
ProductID: "777"
UnitPrice: "2024.994"
LineTotal: "6074.982"
```


São linhas de venda que se referem à mesma venda. Como poderíamos agrupar num só documento com um array de “linhas de fatura”?

Transformação/migração de dados

- Exemplo de consulta:

```
db.salesDetails.aggregate(
[
                {
                    $group: {
                      _id: { ReceiptID: "$ReceiptID" },
                       products: {$push:{item:"$ProductID"}}
                    }
                }
])
```

Acumulador:
https://docs.mongodb.com/manual/reference/operator/aggregation/group/#accumulators-group

Transformação/migração de dados

- Output:

```
[
  { _id: '43659',
    products: [
          { item: '776' },
          { item: '777' },
          { item: '778' },
          { item: '771' },
          { item: '772' },
          { item: '773' },
          { item: '774' },
          { item: '714' },
          { item: '716' },
          { item: '709' },
          { item: '712' },
          { item: '711' }
    ]
  } ]
```

Transformação/migração de dados

- Também é possível devolver o iterator de uma uma pipeline de agregação (embora tenha efeitos negativos no desempenho):

```
// Definir a pipeline de agregação
const pipeline = [
{ $match: { status: "active" } },
{ $group: { _id: "$category", total: { $sum: "$value" } } }
];

// Executar a agregação e guardar o cursor
const cursor = db.nome_da_colecao.aggregate(pipeline);

// Utilizar o cursor como iterator
cursor.forEach(doc => printjson(doc));
```

Bibliografia/Referências

- https://www.mongodb.com/pt-br/docs/manual/aggregation/
- Phaltankar, A. Ahsan, J., Harrison, M., Nedov, L. (2020). MongoDB Fundamentals: A hands-on guide to using MongoDB and Atlas in the real world. Packt Publishing

P.PORTO

ESCOLA SUPERIOR DE TECNOLOGIA E GESTÃO

MongoDB: Framework de Agregação

Bruno Oliveira (bmo@estg.ipp.pt)

PEI Processamento Estruturado de Informação