P.PORTO

ESCOLA SUPERIOR DE TECNOLOGIA E GESTÃO

MongoDB: Modelação de dados

Bruno Oliveira (bmo@estg.ipp.pt)

PEI Processamento Estruturado de Informação

Agenda

- Padrões de modelação Mongo:
  - Embedded Document Pattern
  - Subset pattern
- Processo de modelação
- Tipos de Relacionamento

Introdução

- Em bases de dados orientadas por documentos, representamos entidades como documentos;
- No MongoDB, os relacionamentos entre entidades podem ser representados pela técnica de embutir documentos ou por referências;
- Antes de proceder à construção da base de dados é necessário identificar as principais entidades que pretendemos descrever e como estes se relacionam;

Introdução

- O principal desafio do processo de modelação de dados passa por equilibrar as necessidades aplicacionais, as características de desempenho da base de dados e os padrões de recuperação de dados;
- Ao projetar o modelo de dados, devemos ter em consideração a forma como os dados serão utilizados pelas aplicações (ou seja, consultas, atualizações e processamento dos dados), bem como a estrutura inerente dos próprios dados.

Técnicas de Modelação: Embutir documentos

- Ao embutir documentos (*Embedded Document Pattern*) podemos concentrar todo o conteúdo num único documento:

```
user document:
{
    _id: <User1>,
    username: "johndoe",
    firstname: "john",
    lastname: "doe"
    address: {
                city: "Zürich",
                country: "Switzerland"
            },
    contact: {
                phone: "+41 123-123-123",
                email: "jd@jd.com"
            }
}
```

Embedded Address

Embedded contact

Técnicas de Modelação: Embutir documentos

- No slide anterior o relacionamento entre User e Address é de N:1 (um User tem uma morada e uma morada está associada a vários Users)
- Exemplo: Representar as várias moradas (addresses): rua, cidade e país) para cada pessoa (person): nome, NISS:

Pessoa

Morada

```
{
  name: 'Kate Monster',
  ssn: '123-456-7890',
  addresses : [
     { street: '123 Sesame St', city: 'Anytown', cc: 'USA' },
     { street: '123 Avenue Q', city: 'New York', cc: 'USA' }
  ]
}
```

Técnicas de Modelação: Embutir documentos

- A grande vantagem da abordagem anterior é que não é necessário elaborar duas consultas separadas para devolver pessoas e moradas;
- A grande desvantagem é que não podemos relacionar a mesma morada com mais do que uma pessoa (sem a replicar);
- Imagine o seguinte problema: uma cidade mudou de nome. Quantas operações de atualização são necessárias?

Técnicas de Modelação: Embutir documentos

- Incorporar dados relacionados num único documento pode reduzir o número de operações de leitura necessárias para obtenção de dados;
- Em geral, devemos estruturar os documentos para que as aplicações que o utilizam recebam todas as informações necessárias numa única operação de leitura;

Técnicas de Modelação: Embutir documentos

- No entanto, a utilização de documentos embutidos pode levar a documentos de grande dimensão que contêm campos dos quais as aplicações tipicamente não necessitam;
- Os dados desnecessários podem causar uma carga extra e desacelerar as operações de leitura;

Técnicas de Modelação: Relacionamentos entre documentos

- Temos diferentes tipos de relacionamentos:
  - 1:1
  - 1:N
  - M:N

Técnicas de Modelação: Relacionamentos 1:1

- “Um utilizador tem uma morada e uma morada está associada a um utilizador”
- Tipicamente embutimos os documentos.

Técnicas de Modelação: Relacionamento 1:N

- "Um veículo possui várias peças e uma peça está associada a um veículo"
- Considere: Não sabemos ao certo quantas peças cada veículo terá, podem ser algumas dezenas mas também podem ser algumas centenas (tendo sempre um limite expectável);
- Tipicamente criamos um modelo de dados que use documentos embutidos para descrever um relacionamento de um para muitos entre dados conectados.
- No entanto, temos de ter em consideração se existem padrões de recuperação apenas para peças, o que poderá implicar uma coleção separada só para as peças.

Técnicas de Modelação: Relacionamento 1:N

- Considere que se pretende modelar Editoras e Livros.
- A incorporação do documento da editora dentro do documento do livro levaria à repetição dos dados da editora.
- Para evitar a repetição dos dados da editora, podemos utilizar referências e manter as informações da editora numa coleção separada da coleção de livros (desde que os requisitos de recuperação o justifiquem).
- Ao usar referências, o crescimento dos relacionamentos determina onde armazenar a referência.

Técnicas de Modelação: Relacionamentos N:N

- "Um Livro tem vários autores e um autor tem vários livros"
- Depende dos padrões de recuperação. Especificamente para a associação entre autores e livros:
  - Se as consultas forem essencialmente por livro:

```
{
    _id: "book001",
    title: "Cell Biology",
    authors: [
      {
          author_id: "author124",
          name: "Ellie Smith"
      },
      {
          author_id: "author381",
          name: "John Palmer"
      }
    ]
}
```

Técnicas de Modelação: Relacionamentos N:N

- Se as consultas forem essencialmente por autor:
- No primeiro caso poderia existir uma coleção separada para autores e para o segundo caso uma coleção de livros.

```
{
    _id: "author124",
    name: "Ellie Smith",
    books: [
      {
       _id: "book001",
       title: "Cell Biology",
      },
      {
       _id: "book002",
       title: "Anatomy and Physiology",
      }
    ]
}
```

Padrões de desenho: Subset Pattern

- Para mitigar o problema, podemos utilizar o padrão: Subset para recuperar o subconjunto de dados que é acedido com mais frequência numa única operação de leitura;
- Ao invés de armazenar todos os dados numa única coleção, podemos dividir a coleção em duas novas coleções (Subset Pattern);

Padrões de desenho: Subset Pattern

- Podemos utilizar o padrão do subconjunto para aceder apenas aos dados exigidos, ao invés de todo o conjunto de dados incorporados.

```
{
  "_id": 1,
  "name": "Super Widget",
  "description": "This is the most useful item in your toolbox.",
  "price": { "value": NumberDecimal("119.99"), "currency": "USD" },
  "reviews": [
    {
      "review_id": 786,
      "review_author": "Kristina",
      "review_text": "This is indeed an amazing widget.",
      "published_date": ISODate("2019-02-18")
    },
    {
      "review_id": 785,
      "review_author": "Trina",
      "review_text": "Nice product. Slow shipping.",
      "published_date": ISODate("2019-02-17")
    },
    ...
    {
      "review_id": 1,
      "review_author": "Hans",
      "review_text": "Meh, it's okay.",
      "published_date": ISODate("2017-12-06")
    }
  ]
}
```

Apenas mais recentes

Padrões de desenho: Subset Pattern

- As reviews são ordenadas em ordem cronológica inversa. Quando um utilizador visita uma página de um produto, a aplicação carrega as dez reviews mais recentes.
- Por isso,, podemos optar por armazenar as mais antigas numa coleção separada e incorporar as mais recentes.

Padrões de desenho: Subset Pattern

```
{
  "review_id": 786,
  "product_id": 1,
  "review_author": "Kristina",
  "review_text": "This is indeed an amazing widget.",
  "published_date": ISODate("2019-02-18")
}
{
  "review_id": 785,
  "product_id": 1,
  "review_author": "Trina",
  "review_text": "Nice product. Slow shipping.",
  "published_date": ISODate("2019-02-17")
}
...
{
  "review_id": 1,
  "product_id": 1,
  "review_author": "Hans",
  "review_text": "Meh, it's okay.",
  "published_date": ISODate("2017-12-06")
}
```

Cada análise contém uma referência ao produto para o qual foi escrita.

Padrões de desenho: Subset Pattern

- A utilização de documentos mais pequenos contendo dados de acesso mais frequentes reduz o tamanho global do conjunto de trabalho.
- Estes documentos mais pequenos resultam num melhor desempenho de leitura para os dados a que a aplicação acede com mais frequência.

Padrões de desenho: Subset Pattern

- No entanto, o padrão do subconjunto resulta em duplicação de dados.
- No exemplo anterior, as reviews são mantidas na coleção de produtos e na coleção de reviews.
- Devem ser tomadas medidas adicionais para assegurar que as reviews sejam consistentes entre cada colecção.

Múltiplas Coleções

- Existem cenários em que ter colecções separadas faz sentido.
- Se uma entidade pode ser pensada como uma entidade separada e independente, muitas vezes faz sentido ter uma coleção separada;
- Nestes casos, podemos otimizar a estrutura utilizando o padrão: Subset discutido anteriormente.

Múltiplas Coleções - Exemplo

Order Collection

```
{
 _id: ObjectId("507f1f77bcf86cd799439011"),
 date: ISODate("2019-02-18"),
 customer_id: 123,
 order: [
  {
     product: "widget",
     qty: 5,
     cost: {
        value: NumberDecimal("11.99"),
        currency: "USD"
     }
  }
 ]
}
```

Customer Collection

```
{
    _id: 123,
    name: "Katrina Pope",
    street: "123 Main St",
    city: "Somewhere",
    country: "Someplace",
    ...
}
```

Inventory Collection

```
{
    _id: ObjectId("507f1f77bcf86cd111111111"),
    name: "widget",
    cost: {
       value: NumberDecimal("11.99"),
       currency: "USD"
    },
    on_hand: 98325,
    ...
}
```

Múltiplas Coleções

- De um ponto de vista de desempenho torna-se problemático, uma vez que precisamos de “juntar as peças” para uma ordem específica.
- Um cliente pode ter N encomendas, criando um relacionamento 1-N;
- Incorporar toda a informação sobre um cliente para cada encomenda apenas para reduzir as operações de Junção (lookup) resulta numa grande quantidade de informação duplicada.
- Além disso, nem toda a informação sobre um cliente pode ser necessária para uma encomenda.

Múltiplas Coleções

- O padrão: Extended Reference, proporciona uma óptima forma de lidar com estas situações;
- Ao invés de duplicarmos toda a informação sobre o cliente, apenas duplicamos os campos a que temos acesso com frequência/prioridade.

Múltiplas Coleções

Customer Collection

```
{
    _id: 123,
    name: "Katrina Pope",
    street: "123 Main St",
    city: "Somewhere",
    country: "Someplace",
    date_of_birth: ISODate("1992-11-03"),
    social_handles: [
         twitter: "@somethingamazing123"
    ]
    ...
}
```

Order Collection

```
{
 _id: ObjectId("507f1f77bcf86cd799439011"),
 date: ISODate("2019-02-18"),
 customer_id: 123,
 shipping_address: {
  name: "Katrina Pope",
  street: "123 Main St",
  city: "Somewhere",
  country: "Someplace"
 },
 order: [
  {
  product: "widget",
   qty: 5,
   cost: {
       value: NumberDecimal("11.99"),
       currency: "USD" }
  }
 ],
...
}
```

Múltiplas Coleções

- Algo a considerar na aplicação neste padrão são os dados duplicados;
- Portanto, funciona melhor se os dados que são armazenados no documento principal forem campos que **não mudam frequentemente**.

Computed Pattern

- Existem outros padrões úteis: https://www.mongodb.com/blog/post/building-with-patterns-a-summary.
- O Computed Pattern é utilizado quando temos dados que precisam ser computados repetidamente em nossa aplicação.

Computed Pattern

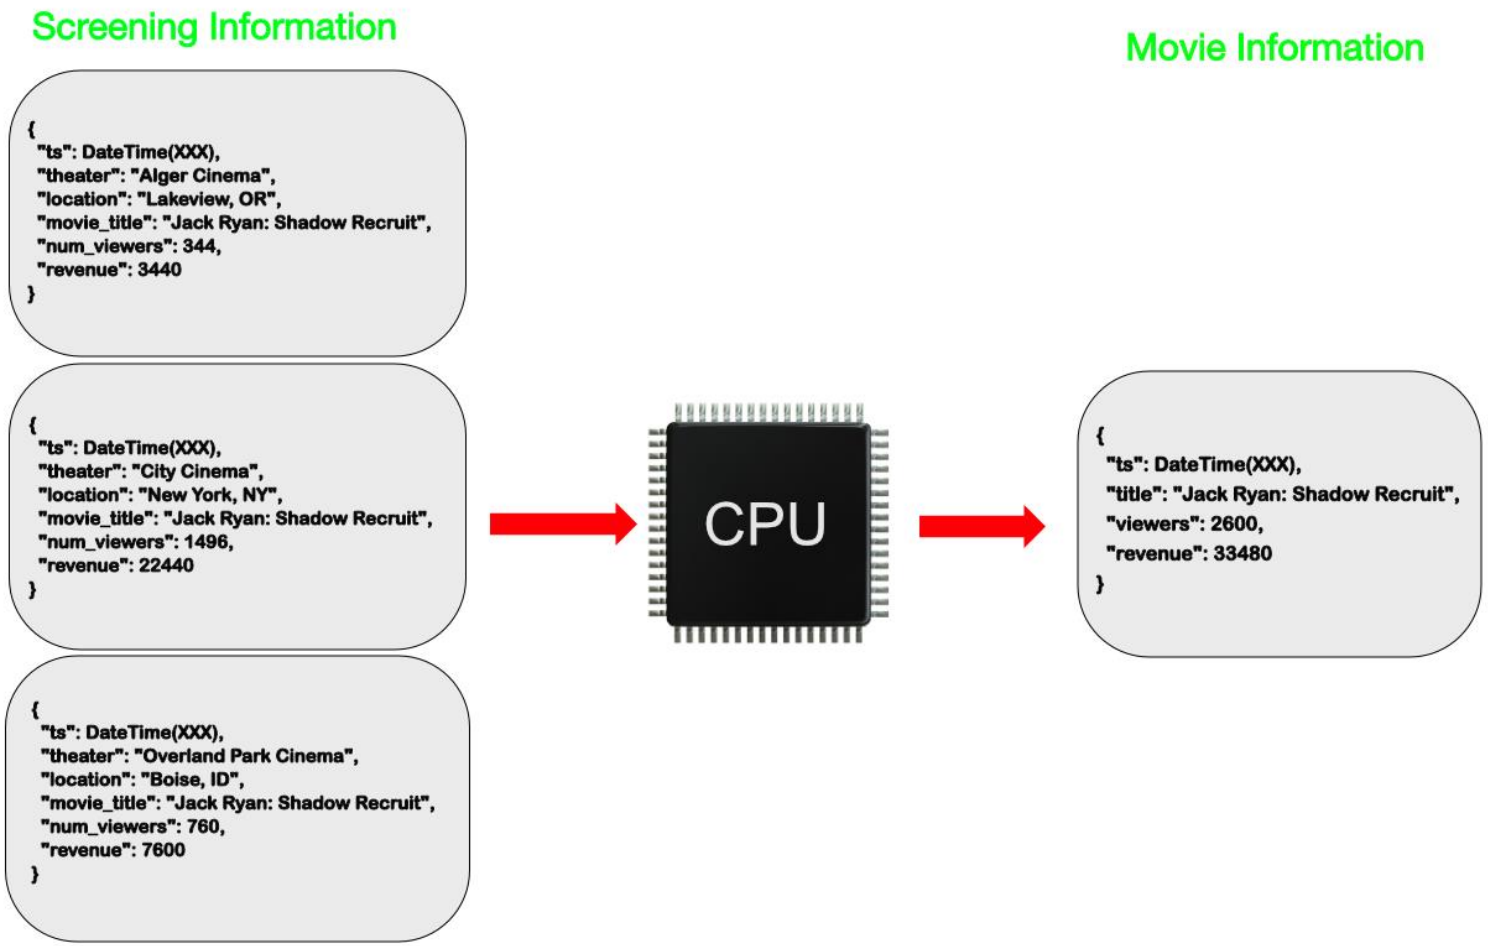

Processo de design

- Tarefas:
  - Identificar as consultas (padrões de recuperação) que executa com mais frequência
  - Identificar os relacionamentos nos dados para decidir se utilizamos referências ou aplicamos a técnica de embutir documentos.
  - Aplicar padrões de design de esquema para otimizar leituras e gravações
  - Criar índices para suportar padrões de query comuns.

Processo de design – Identificar consultas

- Considerar os cenários atuais e os cenários futuros.
- Construir uma tabela:

Ação	Tipo	Dados	Frequência	Priority
Enviar um novo artigo	Escrita	autor, texto	10 por dia	Alta
Enviar um comentário sobre um artigo	Escrita	Utilizador, texto	1,000 per day (100 per article)	Médio
Ver um artigo	Leitura	ID do artigo, texto, comentários	1,000,000 por dia	Alta
Ver análise de artigo	Leitura	ID do artigo, comentários, cliques	10 por hora	Baixo

Processo de design – Identificar Relacionamentos

- Para determinar se devemos embutir ou utilizar referências:
  - Se existem consultas que frequentemente devolvem dados de uma entidade para devolver dados sobre outra entidade, embutimos os dados para evitar a necessidade lookups.
  - Se as consultas atualizam frequentemente os dados relacionados, considere armazenar os dados na sua própria coleção e usar uma referência. Ao utilizar uma referência, reduzimos a carga de trabalho de gravação, uma vez que só atualizamos os dados em um único local.

Processo de design

- Identificar relacionamentos

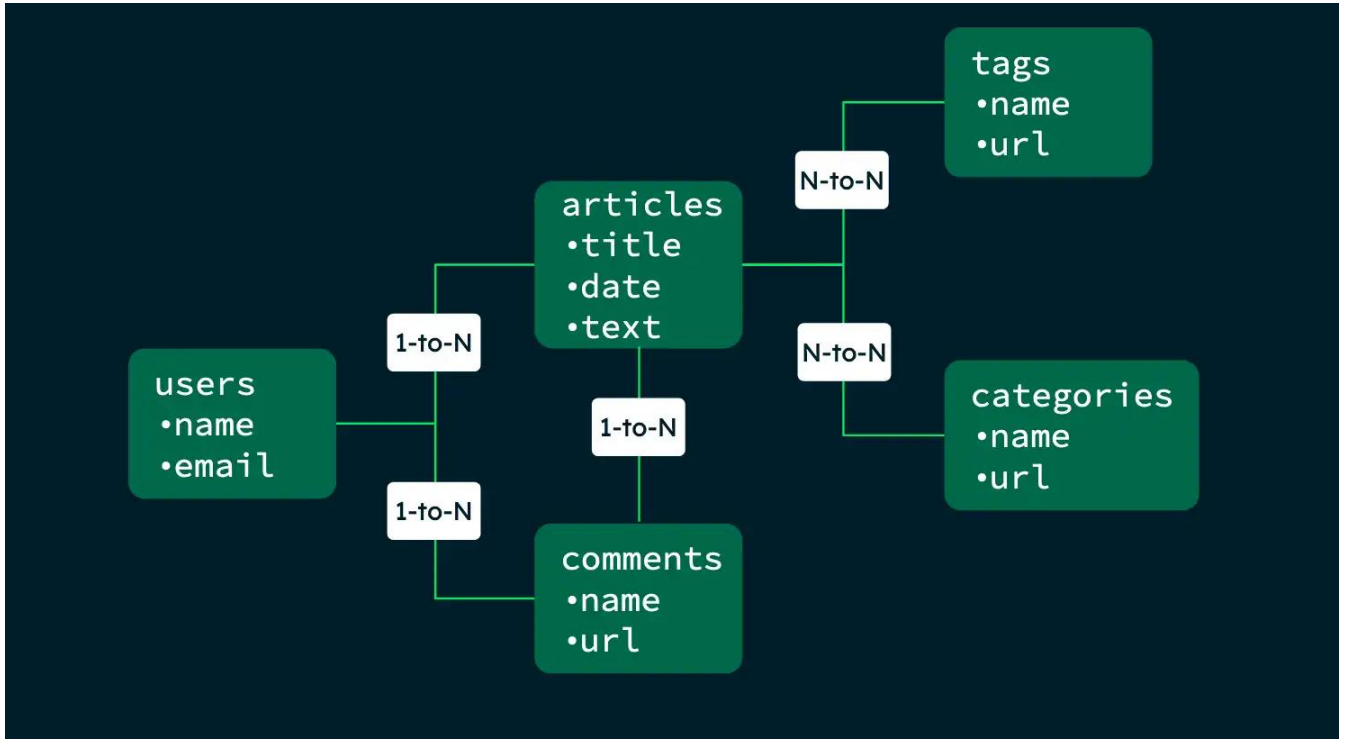

Processo de design – Aplicar Padrões

- Utilizar padrões de design para otimizar o modelo de dados com base nos padrões de recuperação.
- Os padrões de design de esquemas melhoram o desempenho do aplicativo e reduzem a complexidade do esquema.

Processo de design – Índices

- Um índice abrange uma consulta quando o índice contém os campos utilizados pela query.
- Uma coleção pode ter um máximo de 64 índices.
- Para cenários com altas taxas de inserção, os índices podem degradar o desempenho porque cada inserção também deve atualizar índices.

Manipular dados duplicados

- Uma preocupação com a duplicação de dados é o aumento dos custos de armazenamento.
- No entanto, os benefícios da otimização dos padrões geralmente superam os possíveis aumentos de custos do armazenamento.

Manipular dados duplicados

- Antes de duplicar dados, considere os seguintes fatores:
  - Com que frequência os dados duplicados precisam ser atualizados? A atualização frequente de dados duplicados pode causar cargas de trabalho pesadas e problemas de desempenho.
  - No entanto, a lógica extra necessária para lidar com atualizações pouco frequentes é menos dispendiosa do que a execução de junções (pesquisas) em operações de leitura.
  - O benefício em desempenho das leituras quando os dados estiverem duplicados. A duplicação de dados pode eliminar a necessidade de realizar lookups em várias coleções, o que pode melhorar o desempenho do aplicativo.

Resumo

- Embutir o máximo possível: a BD do documento deve eliminar bastante as junções de documentos e por isso devemos colocar o máximo possível de informação num único documento.
- Guardar e recuperar um documento atómico é bastante rápido.

Resumo

- Normalizar os dados que podem ser referenciados em múltiplas entidades ou possuem um número de instâncias indeterminado;
- Isto significa que devemos criar coleções reutilizáveis (por exemplo, país ou utilizador);
- Esta é a forma mais eficiente de lidar com valores duplicados.

Resumo

- O MongoDB pode armazenar documentos com estruturas de dados arbitrárias e profundas, mas não pode efetuar pesquisas de forma eficiente em todos os cenários;
- Se os dados formam uma árvore extensa, deve ser ponderada a estratégia de armazenar dados em documentos separados;
- Consistência: a eficiência de MongoDB implica como consequência a consistência dos dados.

Resumo

- No processo de modelação, as seguintes questões devem ser ainda consideradas:
  - As entidades do lado do N (1:N) necessitam de existir isoladamente?
  - É uma questão que depende do problema. As moradas poderiam existir isoladamente, mas as reviews só existem se existirem restaurantes;
- Considerar a aplicação de padrões de design.

Resumo

- Qual é a cardinalidade do relacionamento 1:N?
  - 1 “para poucos”
  - 1 “para muitos”
  - 1 “para um número indeterminado”

Referências

- Referências Web:
  - https://www.json.org/json-en.html
  - https://docs.mongodb.com/manual/
  - https://docs.mongodb.com/manual/core/data-modeling-introduction/
  - https://docs.mongodb.com/manual/applications/data-models/
  - Hoberman, S., 2014. Data-Modeling for MongoDB-Building Well Designed and Supportable MongoDB Databases, frist. ed. Technics Publications, LLC.
  - https://www.mongodb.com/company/blog/building -with-patterns-a-summary

P.PORTO

ESCOLA SUPERIOR DE TECNOLOGIA E GESTÃO

MongoDB: Modelação de dados

Bruno Oliveira (bmo@estg.ipp.pt)

PEI Processamento Estruturado de Informação